CinéTrans

Pauline Gamel, Daphnée Jerome, Antonin Rossin

Sommaire


Présentation du sujet


Architecture du projet


Détail des différentes parties


Conclusion

Présentation du sujet

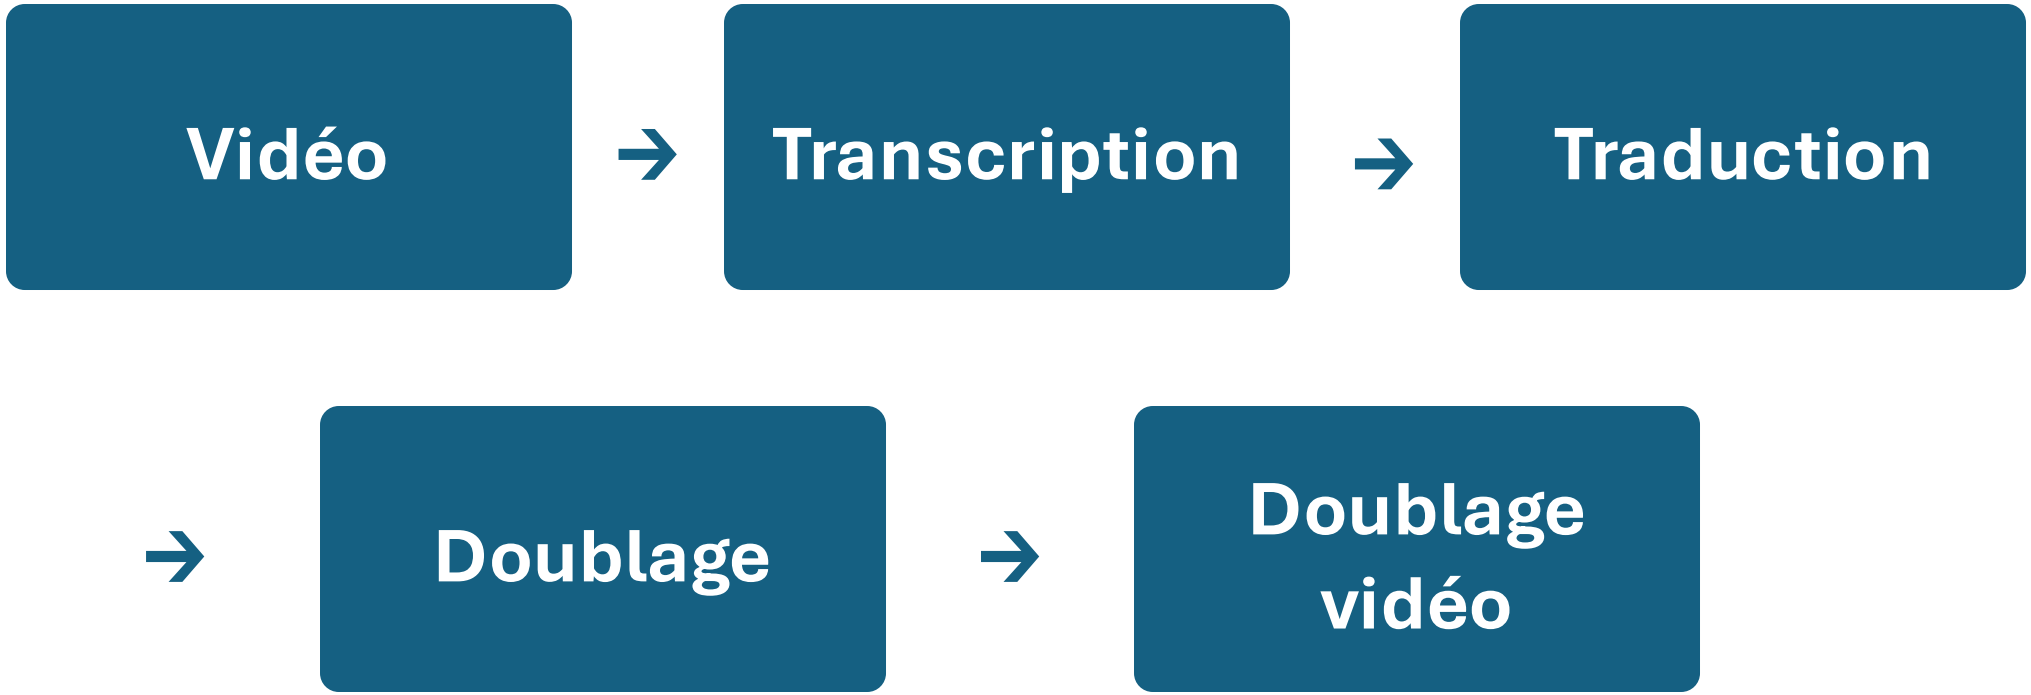
Doublage multi-locuteurs mesuré

Objectif :
Construire une **chaîne complète de doublage** : transcription → segmentation des locuteurs → traduction éventuelle → attribution de voix → resynchronisation.
Le verrou n'est pas l'ambiance sonore, mais la **qualité temporelle et vocale** du résultat.

Contraintes :
Extrait de 3 à 5 minutes, avec au moins 2 locuteurs

Architecture & technologies

Pipeline :



Architecture & technologies

Technos par couches:

Speech to text	WhisperX
diarisation	Pyannote.audio 3.1
Détection d'émotion	Wav2vec2/whisper (dépends de la sélection du modèle)
Traduction	Llm via openrouter
Synthèse vocale	pykokoro
Audio/vidéo	Ffmpeg, soundfile
Web	Flask + html/css/js…
Déploiement	Docker + docker compose

Partie speech to text

Vidéo -> srt

3 étapes:

- Extraction d'audio (ffmpeg)
- Transcription + diarisation (whisper x transcrit et synchronise, pyannote diarise)
- Emotions (wav2vec2 classifieur ou whisper)

Partie traduction

Objectif



Seuls « text » et « language » changent

Même structure en entrée et en sortie : start, end, speaker, emotion restent intacts.

Protéger le JSON

Envoyé au modèle

- Un identifiant par segment
- Le texte source
- Locuteur et émotion
- Durée et longueur indicative

Jamais modifiable

- start et end
- speaker
- emotion
- Réinjection dans le JSON d'origine

Un prompt de traducteur

Oral naturel	Traduire comme quelqu'un qui parle
Émotion	Ton et émotion du segment respectés
Cohérence	Même locuteur, même registre (tu / vous)
Fidélité	Le sens passe avant la longueur

Traduire par lots et respect du temps

15

segments par lot, pour limiter le nombre d'appels

3

segments précédents donnés comme contexte

1 phrase

décrivant la vidéo, avec l'option --context

Le contexte garde un ton et un vocabulaire cohérents d'un lot à l'autre.

17 car/s

débit de parole maximal pour la voix

×1,25

longueur max par rapport au texte source

12 car.

plancher pour les segments très courts

Fidélité d'abord : si c'est trop long, l’audio de la vidéo sera accélérée

Partie text to speech

Objectif

1 vidéo
→ N langues

Entrée

vidéo + segments traduits (JSON)

Sortie

une vidéo doublée par langue

1

Lecture du JSON

segments, locuteurs, langues

2

Choix des voix

1 voix par locuteur

3

Synthèse

modèle Kokoro

4

Calage

vitesse puis coupe

5

Export

piste + video = mp4

Une voix par locuteur

LANG_MAP	Code de langue du JSON → code Kokoro (fr → fr-fr)
VOICES	Plusieurs voix par langue, femmes et hommes
Locuteur → voix	Voix fixe de la première à la dernière réplique

Adaptation temporelle de la voix

Problème : la traduction peut être plus longue que le créneau disponible.

1

Mesurer

Comparer la durée audio au créneau disponible (jusqu'à la réplique suivante).

2

Accélérer

Resynthétiser à une vitesse comprise entre 0,8× et 1,4×, arrondie au dixième lorsque nécessaire.

3

Tronquer

Si encore trop long, coupe avec fondu de 30 ms

Assemblage et export

Piste vide

durée de la vidéo

→

Placement

chaque audio à son start

→

ffmpeg

Résultat : une vidéo doublée par langue

Démonstration

Conclusion

- Production d'une chaine complète de la vidéo à la vidéo traduite

Limites

- Difficulté à concilier la qualité de traduction et le temps de parole, variable selon la langue.
- Qualité de traduction non vérifier
- Voix choisie sans lien avec l'originale et émotions non reproduites
- Son d'origine remplacé (plus d'ambiance)